

Nama : Al Fitra Nur Ramadhani

NIM : 202210370311264

Mata Kuliah : Data Information Knowledge B

Laporan DataPreprocessing & Integration Spotify Tracks

1. Deskripsi

Dataset ini berisi data lagu Spotify dari 125 genre, disimpan dalam format CSV. Setiap lagu memiliki fitur audio seperti popularitas, durasi, danceability, energy, dan lainnya. Dataset ini cocok untuk membangun sistem rekomendasi, klasifikasi berdasarkan fitur audio, atau aplikasi lain seperti analisis genre musik. Kolom data mencakup track_id, nama artis, album, judul lagu, dan berbagai metrik audio seperti loudness, tempo, dan valence, serta genre lagu, dll.


Link Dataset : [Spotify Tracks Dataset](#)

Link GitHub (Jupyter Notebook): [DATA-INFORMATION-
KNOWLEDGE/Spotify/SpotifyTracks/DataPreprocessing.ipynb at main · alfitranurr/DATA-
INFORMATION-KNOWLEDGE](#)

2. Masalah yang Ditemukan

Berdasarkan analisis dataset, beberapa masalah yang diidentifikasi adalah:

- **Kolom Redundan:** Kolom Unnamed: 0 tidak diperlukan karena sudah ada indeks default, menyebabkan redundansi.



- **Missing Values:** Kolom artists, album_name, dan track_name memiliki nilai yang hilang, dengan hanya satu baris yang terdeteksi memiliki missing values.

```
df_missing = df[df.isnull().any(axis=1)]
display(df_missing)
```

#	Unnamed: 0	track_id	artists	album_name	track_name	# popularity
65900	65900	1kR4glb7nGxHPi3D2ifs9	Missing value	Missing value	Missing value	

- **Duplikasi Data:** Terdapat sekitar 40.900 baris duplikat pada kolom track_id, meskipun tidak ada duplikasi pada keseluruhan baris.

```
Baris dengan track_id duplikat:
```















	track_id	artists	album_name	track_name
0	5Su0ikwiRyPMVoIQ0JUGSV	Gen Hoshino	Comedy	Comedy
1	4qPND8W1i3p13qLct8K13A	Ben Woodward	Ghost (Acoustic)	Ghost - Acoustic
5	01MVO19KtVTNFFiBU9I7dc	Tyrone Wells	Days I Will Remember	Days I Will Remember
6	6Vc5wAMmX3IAM7MJoEb7N	A Great Big World;Christina Aguilera	Is There Anybody Out There?	Say Something
7	1EzrEOXmMH3G43AXT1y7pA	Jason Mraz	We Sing. We Dance. We Steal Things.	I'm Yours
9	7k9GuJYlp2AzqokyEdwEw2	Ross Copperman	Hunger	Hunger
12	4ptD3bJl35d7gQfeNteBwp	Dan Berk	Solo	Solo
13	0X9MdhR1rTkEHdjp95F200	Anna Hamilton	Bad Liar	Bad Liar
16	6xKe0gzfJixSUIId14qUezm	Andrew Foy;Renee Foy	ily (i love you baby)	ily (i love you baby)
17	4Yo0igmcNyat1secaH00D	Andrew Foy;Renee Foy	At My Worst	At My Worst
22	5Tve3pk05pyF1GdSY9j4Dj	A Great Big World;Christina Aguilera	Is There Anybody Out There? - Track by Track C...	Say Something
23	0B0uuEvNa5T4lMaewy1udB	Jason Mraz	Coffee Moment	93 Million Miles
24	3Hn3LfhRQ0aK1hdCibJ5Ts	Jason Mraz	Human - Best Adult Pop Tunes	Unlonely
25	6D33wCKzWtNEG0ovgeVJ7r	Jason Mraz	Mellow Adult Pop	Bella Luna
26	5tFCZDRXZr-qZ5m8Awf44PG	Jason Mraz	Holly Jolly Christmas	Winter Wonderland
27	0dzKBptH2P5j5a0M1fBwM4	Jason Mraz	Feeling Good - Adult Pop Favorites	If It Kills Me
28	5QAMZTM5cmlg3fH8X9zbTZi	Jason Mraz	Christmas Time	Winter Wonderland
29	2qESE12eWly713YjyTmxXh	Jason Mraz	Perfect Christmas Hits	Winter Wonderland
30	3EQV1ZtHtHvq90nVRy1dbg3	Jason Mraz	Merry Christmas	Winter Wonderland
31	3ax0rfGb7exdt102L108U9	Jason Mraz	Christmas Music - Holiday Hits	Winter Wonderland
33	3H36x7buZdQD4687VmfFwY	Brandi Carlile;Sam Smith	Human - Best Adult Pop Tunes	Party of One
34	0xbMRcMFqxJl1ka7tWpTn	Brandi Carlile;Sam Smith	Feeling Good - Adult Pop Favorites	Party of One
35	6h061f44HZPj10X02znA45d	Brandi Carlile;Sam Smith	Mellow Bars R'n'B	Party of One
...				
113617	71dLJx3qHOTQMTvvoE2dmd	Bethel Music;Amanda Cook	Peace	King of My Heart
113619	60G5TBcmuT0wMc2SGeTrE	Bethel Music;Brian Johnson;Jenn Johnson	Simple	Simple
113641	7xsrhcgFW0nIt5Gu8frv9	Bethel Music;Steffany Gretzinger	For the Sake of the World	Closer

Jumlah baris dengan track id duplikat: 40900

- **Format Tidak Konsisten:** Kolom track_genre menggunakan huruf kecil dan simbol -, yang perlu diselaraskan untuk konsistensi.

track_genre	
Missing:	0 (0%)
Distinct:	114 (<1%)
114 Distinct values	
alt-rock	
alt-rock	
alt-rock	
alt-rock	
alt-rock	
alt-rock	

- **Data Bernilai Nol:** Beberapa kolom numerik seperti popularity, duration_ms, danceability, dll., memiliki nilai nol yang tidak realistis untuk konteks data.
- **Outlier:** Tidak ditemukan nilai ekstrem yang signifikan berdasarkan analisis boxplot, sehingga dianggap aman.



3. Langkah-langkah dan Alasan Pemilihan Metode Penanganan

Berikut adalah langkah-langkah yang diambil untuk menangani masalah di atas beserta alasannya:

- **Penghapusan Kolom Unnamed: 0**
 - *Langkah:* Kolom ini dihapus.
 - *Alasan:* Kolom ini hanya berfungsi sebagai indeks tambahan yang redundan dengan indeks default pandas, sehingga penghapusan mencegah kebingungan dan menghemat ruang.
- **Penanganan Missing Values**
 - *Langkah:* Missing values pada artists, album_name, dan track_name (satu baris) diisi dengan nilai default atau dihapus jika tidak signifikan. Nilai nol pada kolom numerik (popularity, duration_ms, dll.) diisi dengan median.
 - *Alasan:* Median dipilih karena lebih robust terhadap outlier dibandingkan mean, memastikan data tetap representatif. Penghapusan baris dengan missing values dilakukan jika jumlahnya kecil untuk menjaga integritas dataset.
- **Penanganan Duplikasi**
 - *Langkah:* Baris dengan track_id duplikat dihapus.
 - *Alasan:* Duplikasi pada track_id menunjukkan kemungkinan entri ganda untuk lagu yang sama, yang dapat mengganggu analisis. Penghapusan memastikan setiap lagu hanya muncul sekali.
- **Penyelarasan Format track_genre**
 - *Langkah:* Mengubah huruf kecil menjadi huruf kapital pada setiap kata dan mengganti simbol - dengan spasi.
 - *Alasan:* Format yang konsisten (kapitalisasi dan spasi) meningkatkan keterbacaan dan standarisasi, memudahkan analisis dan visualisasi.
- **Penanganan Nilai Nol**
 - *Langkah:* Mengganti nilai nol pada kolom numerik dengan median.
 - *Alasan:* Nilai nol pada fitur seperti popularity atau danceability tidak realistis dalam konteks musik. Median dipilih untuk menggantikan nilai nol karena tidak terpengaruh oleh distribusi data yang tidak normal.

- **Simulasi Penggabungan Data**

- *Langkah:* Dataset dibagi menjadi dua bagian (info_lagu dan fitur_audio), disimulasikan dengan 80% data fitur_audio, lalu digabungkan menggunakan berbagai tipe merge (inner, left, right, outer).
- *Alasan:* Pemisahan dataset mencerminkan skenario dunia nyata di mana data informasi lagu dan fitur audio mungkin berasal dari sumber berbeda. Berbagai tipe merge digunakan untuk memahami dampaknya:
 - *Inner merge:* Memastikan hanya data lengkap yang digunakan, cocok untuk analisis yang membutuhkan semua fitur.
 - *Left merge:* Mempertahankan semua lagu dari info_lagu, berguna jika informasi lagu lebih penting.
 - *Right merge:* Mempertahankan semua data audio, relevan jika fitur audio menjadi fokus.
 - *Outer merge:* Menggabungkan semua data, membantu mengidentifikasi data yang hilang untuk penanganan lebih lanjut.

4. Kesimpulan

Preprocessing yang dilakukan berhasil menangani masalah redundansi, missing values, duplikasi, dan inkonsistensi format dengan metode yang robust seperti median untuk nilai nol dan penghapusan duplikat. Simulasi penggabungan data memberikan wawasan tentang cara mengintegrasikan dataset dengan struktur berbeda, mempersiapkan data untuk analisis lebih lanjut dengan kualitas yang lebih baik.