

Nama : Al Fitra Nur Ramadhani

NIM : 202210370311264

Mata Kuliah : Data Information Knowledge B

Laporan DataPreprocessing & Integration Spotify Tracks

1. Deskripsi

Dataset ini berisi data lagu Spotify dari 125 genre, disimpan dalam format CSV. Setiap lagu memiliki fitur audio seperti popularitas, durasi, danceability, energy, dan lainnya. Dataset ini cocok untuk membangun sistem rekomendasi, klasifikasi berdasarkan fitur audio, atau aplikasi lain seperti analisis genre musik. Kolom data mencakup track_id, nama artis, album, judul lagu, dan berbagai metrik audio seperti loudness, tempo, dan valence, serta genre lagu, dll.


Link Dataset : [Spotify Tracks Dataset](#)

Link GitHub (Jupyter Notebook) : [DATA-INFORMATION-KNOWLEDGE/Spotify/SpotifyTracks_at_main · alfitranurr/DATA-INFORMATION-KNOWLEDGE](#)

2. Masalah yang Ditemukan

Berdasarkan analisis dataset, beberapa masalah yang diidentifikasi adalah:

- **Kolom Redundan:** Kolom Unnamed: 0 tidak diperlukan karena sudah ada indeks default, menyebabkan redundansi.



- **Missing Values:** Kolom artists, album_name, dan track_name memiliki nilai yang hilang, dengan hanya satu baris yang terdeteksi memiliki missing values.

```

df_missing = df[df.isnull().any(axis=1)]
display(df_missing)

```

#	Unnamed: 0	track_id	artists	album_name	track_name	# popularity
65900	65900	1kR4glb7nGxHPi3D2ifs9	Missing value	Missing value	Missing value	


- **Duplikasi Data:** Terdapat sekitar 40.900 baris duplikat pada kolom track_id, meskipun tidak ada duplikasi pada keseluruhan baris.

```















Baris dengan track_id duplikat:
track_id      artists      album_name      track_name
0      5Su0ikwiRyPMVoIQ0JUGSV      Gen Hoshino      Comedy
1      4qPND8W1i3p13qLct8K13A      Ben Woodward      Ghost (Acoustic)
5      01MVO19KtVTNFfIBU9I7dc      Tyrone Wells      Days I Will Remember
6      6Vc5wAMmXDJAM7WJ0Eb7N      A Great Big World;Christina Aguilera      Is There Anybody Out There?
7      1EzrEOXmMH3G43AXT1y7pA      Jason Mraz      Say Something
9      7k9GuYLP2AzqokyEdwEw2      Ross Copperman      We Sing. We Dance. We Steal Things.
12     4ptD3b1J35d7gQfeNteBwp      Dan Berk      Hunger
13     0X9MdhR1rTkEHdjp95F200      Anna Hamilton      Solo
16     6xKe0gzfj1xSUIId14qUezm      Andrew Foy;Renee Foy      Bad Liar
17     4Yo01gmcoNyat1secaH00D      Andrew Foy;Renee Foy      ily (i love you baby)
22     5Tve3pk05pyTIGdSY9j4DJ      A Great Big World;Christina Aguilera      At My Worst
23     0B0uuEvNa5T41Maewy1udB      Jason Mraz      Is There Anybody Out There? - Track by Track C...
24     3Hn3LfhRQ0aK1hdCibJ5Ts      Jason Mraz      Say Something
25     6D33wCKzWtNEG0ovgeVJ7r      Jason Mraz      Coffee Moment
26     5tFCZDRXZr-q2Sm8Awf44PG      Jason Mraz      93 Million Miles
27     0dzKBphtH2P5j5a0M1fBwM4      Jason Mraz      Human - Best Adult Pop Tunes
28     5QAMZTM5cmlg3fH8X2bTZ1      Jason Mraz      Mellow Adult Pop
29     2qESE12eWly713YjyTXmXh      Jason Mraz      Holly Jolly Christmas
30     3EQV1ZtHtHvq90nVRVY1dbg3      Jason Mraz      Feeling Good - Adult Pop Favorites
31     3ax0rfGb7exdt102L108U9      Jason Mraz      Christmas Time
33     3H36x7buZdQD4687VmfRwY      Brandi Carlile;Sam Smith      Perfect Christmas Hits
34     0xbMRcMFqxJq1kMa7tWpTn      Brandi Carlile;Sam Smith      Merry Christmas
35     6h061f44HZPj10X02znA45d      Brandi Carlile;Sam Smith      Christmas Music - Holiday Hits
...                                     ...
113617 71dLJx3qHOTQMTvvoE2dmd      Bethel Music;Amanda Cook      Human - Best Adult Pop Tunes
113619 60G5TBcmuT0wMc2SGeTrE      Bethel Music;Brian Johnson;Jenn Johnson      Christmas Music - Holiday Hits
113641 7xsrhcgFW0nItSGu8frv9      Bethel Music;Steffany Gretzinger      Merry Christmas
Jumlah baris dengan track_id duplikat: 40900

```

- **Format Tidak Konsisten:** Kolom track_genre menggunakan huruf kecil dan simbol -, yang perlu diselaraskan untuk konsistensi.



- **Data Bernilai Nol:** Beberapa kolom numerik seperti popularity, duration_ms, danceability, dll., memiliki nilai nol yang tidak realistis untuk konteks data.
- **Outlier:** Tidak ditemukan nilai ekstrem yang signifikan berdasarkan analisis boxplot, sehingga dianggap aman.



3. Langkah-langkah dan Alasan Pemilihan Metode Penanganan

Berikut adalah langkah-langkah yang diambil untuk menangani masalah di atas beserta alasannya:

- **Penghapusan Kolom Unnamed: 0**
 - *Langkah:* Kolom ini dihapus.
 - *Alasan:* Kolom ini hanya berfungsi sebagai indeks tambahan yang redundan dengan indeks default pandas, sehingga penghapusan mencegah kebingungan dan menghemat ruang.
- **Penanganan Missing Values**
 - *Langkah:* Missing values pada artists, album_name, dan track_name (satu baris) diisi dengan nilai default atau dihapus jika tidak signifikan. Nilai nol pada kolom numerik (popularity, duration_ms, dll.) diisi dengan median.
 - *Alasan:* Median dipilih karena lebih robust terhadap outlier dibandingkan mean, memastikan data tetap representatif. Penghapusan baris dengan missing values dilakukan jika jumlahnya kecil untuk menjaga integritas dataset.
- **Penanganan Duplikasi**
 - *Langkah:* Baris dengan track_id duplikat dihapus.
 - *Alasan:* Duplikasi pada track_id menunjukkan kemungkinan entri ganda untuk lagu yang sama, yang dapat mengganggu analisis. Penghapusan memastikan setiap lagu hanya muncul sekali.
- **Penyelarasan Format track_genre**
 - *Langkah:* Mengubah huruf kecil menjadi huruf kapital pada setiap kata dan mengganti simbol - dengan spasi.
 - *Alasan:* Format yang konsisten (kapitalisasi dan spasi) meningkatkan keterbacaan dan standarisasi, memudahkan analisis dan visualisasi.
- **Penanganan Nilai Nol**
 - *Langkah:* Mengganti nilai nol pada kolom numerik dengan median.
 - *Alasan:* Nilai nol pada fitur seperti popularity atau danceability tidak realistis dalam konteks musik. Median dipilih untuk menggantikan nilai nol karena tidak terpengaruh oleh distribusi data yang tidak normal.

- **Simulasi Penggabungan Data**

- *Langkah:* Dataset dibagi menjadi dua bagian (info_lagu dan fitur_audio), disimulasikan dengan 80% data fitur_audio, lalu digabungkan menggunakan berbagai tipe merge (inner, left, right, outer).
- *Alasan:* Pemisahan dataset mencerminkan skenario dunia nyata di mana data informasi lagu dan fitur audio mungkin berasal dari sumber berbeda. Berbagai tipe merge digunakan untuk memahami dampaknya:
 - *Inner merge:* Memastikan hanya data lengkap yang digunakan, cocok untuk analisis yang membutuhkan semua fitur.
 - *Left merge:* Mempertahankan semua lagu dari info_lagu, berguna jika informasi lagu lebih penting.
 - *Right merge:* Mempertahankan semua data audio, relevan jika fitur audio menjadi fokus.
 - *Outer merge:* Menggabungkan semua data, membantu mengidentifikasi data yang hilang untuk penanganan lebih lanjut.

4. Kesimpulan

Preprocessing yang dilakukan berhasil menangani masalah redundansi, missing values, duplikasi, dan inkonsistensi format dengan metode yang robust seperti median untuk nilai nol dan penghapusan duplikat. Simulasi penggabungan data memberikan wawasan tentang cara mengintegrasikan dataset dengan struktur berbeda, mempersiapkan data untuk analisis lebih lanjut dengan kualitas yang lebih baik.